



UNIVERSITATEA DIN
BUCUREȘTI

FACULTATEA DE
MATEMATICĂ ȘI
INFORMATICĂ



SPECIALIZAREA INFORMATICĂ

Lucrare de licență

SIMPLIFICARE DE TEXT PENTRU LIMBA ROMÂNĂ

Absolvent
Anghel Fabian

Coordonator științific
Conf.dr. Nisioi Sergiu

București, iunie 2025

Rezumat

În această lucrare prezint un framework inspirat de LSBert [19] care, alături de modele pentru generarea de predicții pentru limbaj mascat, poate fi folosit pentru a simplifica texte în limba română. De asemenea, am comparat diverse modele pentru prezicerea cuvintelor pentru a-l determina pe cel mai potrivit, atât pentru generarea de cuvinte candidat pentru simplificarea unui termen anume și clasarea lor, cât și pentru simplificarea propriu-zisă a propozițiilor. Cel mai performant model a fost *dumitrescustefan/bert-base-romanian-cased-v1* [5], un model BERT [4] antrenat pe limba română, atât prin rezultate, cât și prin eficiență, fiind necesare resurse computaționale puține.

Abstract

In this thesis I present a framework inspired by LSBert [19] that, together with masked language models, can be used for text simplifications in Romanian. I also compared multiple models for word predictions in order to determine the most suitable one, both for generating word candidates for simplifying a specific term and their rankings, and for full sentence simplifications. The best performing model was *dumitrescustefan/bert-base-romanian-cased-v1* [5], a BERT model trained for Romanian, both in results and efficiency, not requiring significant computational resources.

Cuprins

1	Introducere	5
1.1	Motivație	5
1.2	Lucrări înrudite	5
1.3	Contribuții	6
2	Algoritm	7
2.1	Preliminarii	7
2.2	Descrierea algoritmului	8
2.2.1	Identificarea cuvintelor complexe	8
2.2.2	Generarea de candidați	8
2.2.3	Clasarea candidaților	9
2.2.4	Selectarea candidatului și înlocuirea	10
2.3	Simplificarea unui cuvânt specific	10
3	Metode	11
3.1	Simplificare Lexicală	11
3.1.1	Set de date	11
3.1.2	Modele	11
3.1.3	Evaluare	13
3.2	Simplificare de Propoziții	13
3.2.1	Set de date	13
3.2.2	Modele	14
3.2.3	Evaluare	14
4	Rezultate	16
4.1	Simplificare Lexicală	16
4.1.1	Rezultatele metricilor	16
4.1.2	Rezultatele modelelor	18
4.2	Simplificare de Propoziții	19
4.3	Rezultate Totale	22

5	Concluzii	23
5.1	Lucrări viitoare	23
	Bibliografie	25
A	Simplificare Lexicală	28
B	Modelul BERT-Romanian Antrenat	30
C	Simplificare de Propoziții	32
C.1	Exemple de Simplificări	33
C.1.1	Exemple de Simplificări Foarte Bune	33
C.1.2	Exemple de Simplificări Slabe	35

Capitolul 1

Introducere

1.1 Motivație

Rolul Simplificării de Text este de a înlocui anumite cuvinte sau fraze dintr-un text cu termeni familiari sau de a adăuga explicații la anumite noțiuni, toate cu scopul de a transforma un anumit text într-unul mai ușor de înțeles. Acest lucru poate fi folositor mai multor grupuri de oameni să înțeleagă un anumit fragment mai bine prin utilizarea de cuvinte cunoscute, inclusiv copii, persoane cu dizabilități, sau vorbitori străini care vor să învețe o anumită limbă sau să o înțeleagă mai bine.

Specific pentru limba română, există puține modalități de a face simplificare de text, și cu atât mai puține sunt uneltele sau seturile de date care ar putea ajuta la simplificare sau la crearea unor modele de simplificare de text. Scopul acestei lucrări este de a introduce o posibilă soluție pentru acest task, fără a utiliza intensiv resurse computaționale și folosind date și modele preantrenate deja disponibile. Mai mult, este prezentat un framework ce poate fi extins pe viitor, odată cu alte avansări în domeniul Procesării Limbajului Natural.

1.2 Lucrări înrudite

Principala inspirație pentru această lucrare este LSBert [19], ce implementează un algoritm pentru a înlocui anumite cuvinte dintr-o propoziție cu sinonime sau alți termeni înrudiți care sunt mai frecvent folosiți în limbă și sunt mai ușor de identificat și de înțeles. El identifică termenii complecși dintr-o anumită frază și se folosește de modelul preantrenat BERT [4], un MLM (Masked Language Model sau Model de Limbaj Mascat) care, într-o anumită secvență, pentru token-uri mascate (marcate de obicei cu cuvântul cheie [MASK]), încearcă să prezică cuvinte ce pot servi drept înlocuire la acel token, luând în calcul întregul context, anterior și posterior măștii. Pentru a genera posibile substituții se folosește de un prompt specific de forma: „[CLS] propoziție originală [SEP] propoziție mascată [SEP]”, unde propoziția mascată reprezintă propoziția originală, dar în care cu-

vântul țintă este înlocuit de masca specifică [MASK]. În final, sunt ordonate predicțiile folosind diverse criterii (probabilitatea de apariție a cuvântului dată de BERT, frecvența cuvântului în limbaj, similaritatea între cuvântul original și substituție, un model de limbaj bazat pe BERT, și PPDB [7]) și se ia candidatul cu scorul cel mai bun și, după ce se verifică dacă reprezintă un termen mai ușor de înțeles decât cel original, se face substituția.

Există o implementare care acoperă și limba română, aceea fiind MILES [11], dar este intenționată pentru folosirea cu mai multe limbi posibile, utilizând BERT-multilingual [4] ca MLM, dar fără a lua în considerare caracteristicile specifice ale unui limbaj sau resurse destinate acestuia.

1.3 Contribuții

În această lucrare prezint implementarea mea pentru un algoritm de simplificare de text ce folosește ca bază un model de limbă mascată, inspirat de LSBert [19]. Modificările aduse sunt cele legate de caracteristicile specifice limbii române, fiind proiectat în jurul acestora. De asemenea, am extras date din diverse surse ce sunt folosite ca materiale legate de cuvinte din limba română de algoritmul implementat.

Contribuțiile mele se extind și la evaluare. Am implementat integrarea LLM-urilor pentru a folosi la generarea de predicții pentru limbaj mascat, la apelarea prompt-urilor folosite și la extragerea predicțiilor oferite. Am extras seturi de date folosite pentru evaluare, mai specific propozițiile pe care se testează simplificarea. Am implementat o interfață de adnotare a simplificărilor rezultate și la adnotarea propriu-zisă a datelor. Am antrenat un model BERT [4] pentru compararea cu un model preantrenat. În final am contribuit la colectarea evaluărilor și calcularea rezultatelor.

Capitolul 2

Algoritm

2.1 Preliminarii

Am implementat un framework asemănător cu LSBert [19], luând în considerare ideea de bază și aceiași pași (detectare de cuvinte complexe, generarea de predicții folosind un model BERT [4], ordonarea candidaților, înlocuirea în propoziție), dar folosind resurse disponibile pentru limba română, astfel venind și modificări la nivelul implementării pașilor. Pentru predicții se poate folosi orice model BERT sau orice alt model atât timp cât returnează parametrii asemănători cu un model BERT (mai specific să se returneze pentru fiecare cuvânt parametrii *score* și *token_str*).

Tot codul pentru algoritm a fost scris în limbajul de programare Python. A fost folosită librăria spaCy [8] pentru împărțirea unui text în propoziții, respectiv a propozițiilor în tokeni, dar și pentru funcționalitățile de lematizare a cuvintelor, de identificare a părților de vorbire, de detectare a interdependențelor dintre termeni în propoziție. A fost folosit pipeline-ul *ro_core_news_lg*. A fost folosită și librăria fastText [10] cu modelul pentru limba română, pentru a obține reprezentări ale cuvintelor în vectori, folosite pentru a determina cât de apropiate sunt două cuvinte ca sens. Pentru scorul de frecvență a cuvintelor în limbaj s-a utilizat librăria wordfreq [25], și mai exact frecvența Zipf, drept o metrică pentru complexitatea cuvintelor.

Au fost extrase date și din dicționare online disponibile pentru limba română. De pe pagina dictionardesinonime.ro [1] au fost extrase sinonime și antonime pentru cuvinte. Din baza de date publică a dexonline [2] au fost extrase și folosite toate inflexiunile (formele la diferite genuri, numere, cazuri, timpuri, persoane) disponibile pentru toate cuvintele.

Pentru preprocesare, au fost făcuți doi pași. Primul a fost împărțirea textului în propoziții, ca apoi simplificările să aibă loc la nivel de enunț. Celălalt a fost înlocuirea diverselor litere cu diacritice cu versiunea corectă a lor. Ele pot apărea ori cu cod unicode diferit față de cel standard, ori să fie separate diacriticele de litera propriu-zisă. Acest

pas a fost făcut și pentru a reda consistență între texte, dar și pentru a avea input corect pentru modelele de limbaj mascat.

2.2 Descrierea algoritmului

2.2.1 Identificarea cuvintelor complexe

Primul pas în proces este identificarea cuvintelor complexe într-o propoziție, folosind diverse criterii. Mai întâi sunt excluse date esențiale din text ce nu pot fi înlocuite, precum link-uri către pagini, email-uri, nume și entități cu nume, dar și numere și numerale. Sunt eliminate și semnele de punctuație, spațiile și alte semne dacă au fost detectate ca token separat. Ca părți de vorbire se iau în considerare pentru simplificare doar substantive, adjective, verbe și adverbe, încât ele sunt singurele care ar putea avea posibile sinonime sau cuvinte înrudite mai simple cu care pot fi înlocuite, iar restul părților, precum pronume, conjuncții, articole și prepoziții, sunt ignorate. Un criteriu mai deosebit a fost excluderea pentru simplificare a direcțiilor cardinale după ce am făcut observația că de multe ori erau schimbate în propoziția simplificată, deseori cu o complet altă direcție, deși nu au alte posibile înlocuiri mai puțin complexe și se schimbă sensul textului. Ultimul criteriu și cel mai important a fost frecvența Zipf a unui cuvânt. Întrucât pentru limba română modelul care-o calculează a fost antrenat pe un set mai mic de date, scorurile pornesc de la 3 și am considerat o frecvență de 4.25 ca fiind destul de complexă pentru ca un cuvânt să fie considerat pentru simplificare.

Ordinea simplificării este dată tot de aceeași frecvență, cuvintele cu scorul cel mai mic fiind luate în considerare primele. După fiecare simplificare, se face imediat înlocuirea în propoziția originală și se reia căutarea cuvintelor complexe, pentru a lua în calcul și noul context. Cuvintele care au fost modificate sunt adăugate într-o listă pentru a fi ignorate și pentru a nu se reîncerca simplificarea lor. Dacă nu se mai identifică niciun cuvânt complex sau nu se mai poate face nicio simplificare, algoritmul se oprește și returnează propoziția simplificată.

2.2.2 Generarea de candidați

Următorul pas, după ce un cuvânt a fost identificat ca fiind complex, este să se genereze posibili candidați ce pot înlocui și simplifica cuvântul. În majoritatea cazurilor, procesul constă în folosirea unui model de limbaj mascat cu un prompt de forma: „[CLS] propoziție originală [SEP] propoziție mascată [SEP]”, unde propoziția mascată constă în înlocuirea cuvântului țintă în token-ul de mască [MASK] în propoziția originală, cea dată pentru simplificare. Tokenii [CLS] și [SEP] semnifică începutul unei propoziții, respectiv îmbinarea a două enunțuri diferite, în acest caz fiind cea originală și versiunea mascată. Modelul va returna după aceea o listă pentru posibile cuvinte în locul token-ului mască,

împreună cu probabilități sau scoruri pentru fiecare, prin parametrii *token_str*, respectiv *score*. Propoziția originală este folosită și ea în prompt pentru a indica modelului cuvântul original și contextul în care se află. După aceea, se face o filtrare la nivelul rezultatelor astfel încât, pe lângă faptul că predicțiile trebuie să reprezinte cuvinte întregi, trebuie să se păstreze și partea de vorbire, pentru corectitudinea textului și pentru menținerea aceluiași sens.

Cazul excepțional îl reprezintă substantivele care, pe lângă candidații generați normali, mai primesc o serie de posibile simplificări rezultate prin modificarea genului cuvântului țintă în propoziția mascată. Acest lucru se face prin identificarea tuturor cuvintelor în relație cu ținta prin interdepențe, precum adjective, articole, numerale sau pronume, și schimbarea genului lor căutând inflexiunile corespunzătoare genului opus. Substantivele neutre sunt considerate masculine dacă sunt la singular și feminine dacă sunt la plural.

2.2.3 Clasarea candidaților

Urmează clasarea predicțiilor valide returnate de model. Sunt considerate 4 criterii în calcularea unui scor final pentru fiecare sugestie. Primul criteriu este probabilitatea de apariție sau scorul dat de modelul de limbă mascată, determinat atunci când au fost generați candidații, reprezentând opinia modelului despre cât de potrivită este sugestia. Modelul ia în calcul și tot contextul propoziției, fapt ce nu este luat în considerare de alte metrici.

Următorul este frecvența Zipf pentru fiecare cuvânt nou, folosită ca o măsură de complexitate. În majoritatea cazurilor, cu cât un cuvânt este mai frecvent folosit în limbaj, cu atât reprezintă un termen mai simplu și este mai ușor de înțeles. Frecvența Zipf a unui cuvânt reprezintă logaritmul în bază 10 al numărului aparițiilor per miliard de cuvinte.

Al treilea criteriu este dat de similaritatea semantică între cuvântul original și candidat. Se calculează similaritatea în cosinus a reprezentărilor vectoriale ale celor două, indicând apropierea în sens, în domeniu și în contexte de utilizare, căutându-se un termen cât mai apropiat de cel original.

Ultimul criteriu constă într-un scor de sinonimie. Pentru fiecare cuvânt există o listă stocată de sinonime și antonime, și se verifică dacă forma de bază a candidatului este sinonim sau antonim pentru cea a cuvântului țintă sau invers. Scorul este 1 pentru sinonime, 0 pentru antonime, 0.25 dacă cuvintele au aceeași leamă sau formă de bază și 0.5 dacă nu există nicio relație. Scopul este de a aduce o nouă dimensiune scorului final care nu este luată în calcul de similaritatea semantică sau de model, care pot avea scoruri mari pentru antonime deoarece tot sunt similare semantic și în domeniu sau se potrivesc în contextul propoziției. De asemenea, este descurajată sugerarea cuvântului original drept candidat, și astfel se încurajează explorarea altor opțiuni.

În final, pentru fiecare set de scoruri se face o normalizare între 0 și 1 folosind funcția

Softmax pentru a alinia și a aduce în același interval toate criteriile. Pentru fiecare cuvânt se calculează media dintre cele 4 scoruri și se returnează lista de candidați ordonată descrescător.

2.2.4 Selectarea candidatului și înlocuirea

Ultimul pas din algoritm este reprezentat de selectarea celui mai bun candidat și înlocuirea cuvântului original. Selectarea se face prin luarea predicției cu cel mai bun scor în urma clasării. Înlocuirea se face numai dacă frecvența Zipf a simplificării este mai mare decât cea a cuvântului original, pentru a preveni transformarea unei propoziții într-una mai complexă.

La înlocuire, se face mai întâi o verificare a formei, astfel încât inflexiunea simplificării, inclusiv număr, caz, timp și persoană, să corespundă cu cea a cuvântului original. În cazul substantivelor, dacă simplificarea este la genul opus, se ia în considerare această modificare și, în plus, se alterează și celelalte cuvinte, inclusiv adjective, articole, numerale și pronume, care sunt în relație cu cuvântul original. Mai există și un caz special, cel al verbelor la participiu, folosindu-se inflexiunile adjectivului ce provine din participiu în loc de cele ale verbului.

2.3 Simplificarea unui cuvânt specific

Am mai implementat în plus o funcție care primește ca parametri o propoziție și un cuvânt specific și se simplifică toate aparițiile lui. Nu se mai verifică complexitatea lui, ci se generează posibili candidați și se clasează folosind aceleași criterii. Pentru fiecare apariție a cuvântului se returnează lista ordonată de predicții simplificate. Scopul implementării a fost pentru evaluarea generării de candidați, pentru a calcula cât de bună este performanța algoritmului.

Capitolul 3

Metode

S-au luat în considerare două metode diferite de evaluare, și anume Simplificarea Lexicală și Simplificarea de Propoziții. Scopul este de a determina cât de bine se generează lista de candidați ce ar putea înlocui un cuvânt și ordonarea acestora, respectiv opinia umană asupra propozițiilor rezultate în urma simplificărilor făcute. În plus, s-a urmărit și compararea diverselor modele ce ar putea ajuta la simplificare și determinarea modelului ideal.

3.1 Simplificare Lexicală

3.1.1 Set de date

Setul de date constă în propoziții și câte un cuvânt țintă din ele pentru care se face simplificare, urmat de o listă de posibile alternative pentru acel cuvânt, având același sens și fiind ordonate după simplitatea lor. Datele sunt în forma framework-ului de simplificare lexicală MultiLS [16], și setul de date creat pentru acesta „An Extensible Massively Multilingual Lexical Simplification Pipeline Dataset using the MultiLS Framework” [23], reprezentat de propoziții, fiecare cu câte un cuvânt și o listă de termeni alternativi ce îl pot înlocui, ordonați după cât de simpli și cât de potriviți sunt. S-au extras datele pentru limba engleză și au fost traduse automat în limba română, după modelul de traduceri descris în „Archaeology at MLSP 2024” [3]. În total sunt 460 de seturi de propoziții, cuvinte țintă și liste de alternative.

3.1.2 Modele

Au fost evaluate în total 6 modele peste acest set de date, folosind funcția de simplificare a unui cuvânt specific dintr-o propoziție. Dintre ele, 3 sunt modele BERT [4] preantrenate. BERT [4] reprezintă un transformer bidirecțional antrenat pe text neetichetat, ori pentru a prezice tokeni mascați dintr-o propoziție, ori pentru a prezice dacă

o propoziție urmează o alta. În acest caz a fost folosit în scop de model de limbaj mascat. Două dintre modele sunt preantrenate specific pentru limba română, iar ultimul este multilingvistic, dar include și limba română. Modelele sunt toate disponibile pe platforma Hugging Face [6], o platformă online de agregare de modele preantrenate. Cele trei modele sunt:

- *dumitrescustefan/bert-base-romanian-cased-v1* [5]
- *readerbench/RoBERT-large* [15]
- *google-bert/bert-base-multilingual-cased* [4]

Următorul model este tot BERT-Romanian [5], dar antrenat pe acest task specific, împărțind setul de date în set de antrenare și testare. Antrenarea a fost făcută mascând cuvântul țintă din propoziție și calculând cross-entropia pentru fiecare termen alternativ din lista din setul de date. Evaluarea pentru acest model s-a făcut doar pe setul de testare, în loc de întregul set de date. De asemenea, nu s-a folosit algoritmul de simplificare implementat, scopul principal fiind antrenarea unui model pentru generarea de termeni alternativi simplificați fără influența acestuia.

Am folosit și un LLM (large language model): GPT-4o mini [17], folosind un prompt asemănător cu cel utilizat în „The BEA 2024 Shared Task on the Multilingual Lexical Simplification Pipeline” [24], unde a fost utilizat pentru a crea un baseline în task-ul de Lexical Simplification (Simplificare Lexicală). Prompt-ul utilizat este:

```
Context: "{context}"\n
Question: Given the above context, list ten alternative romanian one
word substitutions for [MASK], each with a score. List only the words
without translations, transcriptions or explanations, in the following
format: "x. word - score".\n
Answer:
```

Modificările au fost făcute pentru a imita un model BERT normal, care nu este antrenat specific pentru task-ul de simplificare, clasarea și căutarea celei mai simple și potrivite predicții fiind făcută de algoritm. De asemenea, a fost indicat și în formatul exact în care trebuie returnate rezultatele, pentru a fi făcută mai ușoară extragerea datelor. Contextul este prompt-ul care este dat de algoritm atunci când sunt generați candidați. După utilizarea prompt-ului, sunt extrase cuvintele și scorurile din răspunsul dat în liste cu argumentele *token_str* și *score*, fiind apoi rezultatul returnat algoritmului de simplificare de text.

Ultimul model folosit este tot un LLM, dar antrenat pentru limba română, și anume RoLlama3 [14]. S-a folosit un prompt asemănător cu cel pentru GPT-4o-mini, dar tradus în limba română:

Context: "{context}"\n

Dându-se următorul context, returnează o listă de zece cuvinte drept substituție pentru [MASK], fiecare cu câte un scor. Listează doar cuvintele fără explicații, în următorul format: "x. word - score".\n

Răspuns:

Scopul a fost compararea dintre un LLM general și unul instruit pe bază de instrucțiuni specific pentru limba română și cât de bine sunt pricepute pe un task de cuvânt mascat. La fel ca pentru GPT-4o-mini, sunt extrase cuvintele în liste cu argumentele *token_str* și *score* și returnate algoritmului de simplificare de text.

3.1.3 Evaluare

Evaluarea constă în compararea predicțiilor date de diferitele modele și lista ordonată de sinonime pentru cuvântul țintă definită de setul de date. Metricile folosite sunt atât cele folosite pentru simplificare lexicală în „The BEA 2024 Shared Task on the Multilingual Lexical Simplification Pipeline” [24], cât și definite în BenchLS [18]:

- Accuracy@k@top1 reprezintă procentul de instanțe în care cel puțin unul din primele k clasate simplificări este sugestia de top în listă.
- MAP@k reprezintă Mean Average Precision și se calculează ca media procentului de predicții ce se află și în listă la fiecare pas.
- Potential@k reprezintă procentul de instanțe în care s-a sugerat cel puțin un cuvânt care se află în listă.
- Recall@k reprezintă procentul de cuvinte din listă care au fost prezise și de model
- Precision@k reprezintă procentul de cuvinte sugerate de model care se află în listă.

Pentru toate metricile @k semnifică faptul că se iau în considerare primele k simplificări sugerate de un model. În plus, pentru patru dintre metrici s-a considerat și cazul în care se verifică forma de bază (lema) a cuvintelor prezise cu cele ale celor din listă.

3.2 Simplificare de Propoziții

3.2.1 Set de date

Sunt folosite două seturi de date diferite pentru acest tip de evaluare. Primul set de date este format din propoziții extrase din Romanian Corpus [12], conținând texte din diferite surse (articole de cercetare, literatură română și tradusă, manuale, știri, etc.). Propozițiile au fost extrase după diverse criterii: lungimea propoziției adecvată, număr

îndeajuns de cuvinte ce pot fi simplificate, structură corectă a propoziției (să aibă început și sfârșit), să nu conțină numai nume și numere. Din acestea, a fost ales aleator un subset din ele, rezultând în 460 de propoziții distincte.

Al doilea set de date este reprezentat de propoziții extrase din textele furnizate de MultiplEYE [21, 22] și traduse în limba română. S-au respectat aceleași criterii pentru extragerea lor, rezultând în 117 propoziții distincte.

3.2.2 Modele

Au fost evaluate 4 modele peste cele 2 seturi de date. Trei dintre ele au fost utilizate și la task-ul de simplificare lexicală, fiind folosite cu algoritmul de simplificare de text implementat, dar în schimb cu funcția de simplificare a unei propoziții. Cele trei modele sunt:

- *dumitrescustefan/bert-base-romanian-cased-v1* [5]
- GPT-4o-mini [17]
- *OpenLLM-Ro/RoLlama3-8b-Instruct* [14]

Pentru GPT-4o-mini și RoLlama3 s-au folosit aceleași prompt-uri ca cele menționate anterior.

Ultimul model folosit este MILES [11], fiind tot un algoritm implementat după modelul de la LSBert [19], dar folosind un model de BERT multilingvistic. Scopul folosirii acestuia este de a compara modele specifice, și mai specific cele inspirate de LSBert, pentru limba română cu cele generale, disponibile și pentru alte limbi.

3.2.3 Evaluare

Evaluarea constă într-o serie de evaluări umane după framework-ul Rank & Rate utilizat în LENS [13], în care adnotatorii, primind propoziția originală și simplificările făcute asupra ei de către cele 4 modele, trebuiau să ordoneze cele 4 opțiuni după calitatea

Categorie de Text	Număr de Propoziții
Articole de Cercetare	38
Filozofie	33
Istorie	46
Literatură Română	134
Literatură Tradusă	141
Manuale	35
Știri	33

Tabela 3.1: Propoziții valabile pentru fiecare categorie de text

lor și să ofere un scor între 1 și 10 fiecăruia. S-a restrâns intervalul scorurilor, inițial fiind între 0 și 100, pentru a reduce complexitatea ridicată din a oferi unul. Criteriile includ simplitatea propoziției noi, corectitudinea ei și păstrarea înțelesului original. În total au participat 4 evaluatori.

Interfața a fost implementată în platforma Label Studio [9], folosind elementele de listă clasată pentru partea de Rank, și input pentru un număr pentru Rate, elemente prezente și în Figura 3.1. Platforma a fost găzduită pe versiunea de trial a Railway [20], o platformă online de găzduire de pagini web.

Pentru primul set de date, s-a luat în considerare și domeniile diferite din care provin textele de unde au fost extrase propozițiile din set, așa că s-au considerat și rezultatele pe categorii diferite. Categoriile și numerele sunt prezentate în Tabela 3.1.

#2736
1 of 1

Ți se dă o propoziție și un set de simplificări pentru aceea propoziție generate folosind mai multe modele. Trebuie să ordonezi acele simplificări de la cea mai bună la cea mai nepotrivită și după să dai un scor de la 1-10 pentru fiecare. Ia în considerare următoarele criterii: cât de bună este simplificarea relativ la propoziția originală, cât de bine se înțelege noua propoziție și corectitudinea ei, cât de mult din sensul original s-a păstrat și în simplificare.

Propoziția originală:
Emisiile substanțelor poluante în aerul atmosferic prezintă un risc sporit pentru mediu și sănătatea populației.

Prezența substanțelor chimice în aerul înconjurător prezintă un risc sporit pentru mediu și sănătatea populației.
1

Conținutul substanțelor toxice în aerul aerian prezintă un risc crescut pentru mediu și viața populației.
2

Emisiile substanțelor poluante în aerul atmosferic prezintă un risc sporit pentru mediu și oameni populației.
3

Emisiile minerale naturale în sistemul natural prezintă un risc constant pentru mediu și cultura populației.
4

1) Prezența substanțelor chimice în aerul înconjurător prezintă un risc sporit pentru mediu și sănătatea populației.

2) Conținutul substanțelor toxice în aerul aerian prezintă un risc crescut pentru mediu și viața populației.

3) Emisiile substanțelor poluante în aerul atmosferic prezintă un risc sporit pentru mediu și oameni populației.

4) Emisiile minerale naturale în sistemul natural prezintă un risc constant pentru mediu și cultura populației.

Navigation icons: back, forward, close, undo/redo.

Buttons: Skip, Submit

Figura 3.1: Interfața din label studio a evaluatorilor. Inițial se prezintă instrucțiunile de adnotare și propoziția originală. Urmează, în caseta gri, lista pentru clasare, căreia i se poate schimba ordinea. În final se află din nou propozițiile simplificare, enumerate ca în lista ordonată, împreună cu input-urile pentru scoruri.

Capitolul 4

Rezultate

4.1 Simplificare Lexicală

4.1.1 Rezultatele metricilor

Scopul general al evaluării simplificării lexicale este de a evalua cât de bine reușește un model să genereze candidați, dar și să atribuie scoruri fiecăruia și să-i claseze.

„Accuracy” sau acuratețea (prezentată în Figura 4.1 și în Tabela A.1) are scopul de a măsura cât de bine reușește un model să prezică cea mai bună opțiune din lista de sinonime alternative pentru acel set, ea reprezentând de obicei cea mai simplă și potrivită sugestie. Dacă creșterea nu e așa substanțială cu creșterea parametrului k , atunci se prezintă faptul că cea mai bună alternativă, chiar dacă nu este clasată prima, tot se află printre primii candidați de simplificare.

„MAP” sau „Mean Average Precision” (prezentat în Figura 4.2 și în Tabela A.2) indică performanța sugestiilor de top ale unui model. Un scor mai bun indică dacă predicțiile de top se află în lista de alternative a setului de date, considerate ca fiind cele mai bune.

„Potential” sau potențialul (prezentat în Figura 4.3 și în Tabela A.3) este metrica în




Figura 4.1: Rezultatele pentru metrica Accuracy@k@top1




Figura 4.2: Rezultatele pentru metrica MAP@k




Figura 4.3: Rezultatele pentru metrica Potential@k




Figura 4.4: Rezultatele pentru metrica Recall@k

care modelele au scorul cel mai mare. Cu cât se obține un scor bun pentru un parametru k mai mic, cu atât este mai performant modelul, fiind capabil să genereze o simplificare bună printre primele predicții.

„Recall” (prezentat în Figura 4.4 și în Tabela A.4) este o metrică cu scoruri mai proaste și reprezintă capacitatea unui model de a genera cât mai multe din lista standard de alternative. Dar cuvintele mai prost clasate în setul de date sau cele care nu sunt native limbii române (ținând cont că propozițiile sunt traduse din limba engleză) pot fi omise, justificând performanțele mai slabe.

„Precision” sau precizia (prezentată în Figura 4.5 și în Tabela A.5) este o metrică pentru care, în mod normal, performanța scade odată cu creșterea parametrului k. Scăderea bruscă și scoruri inițiale mai ridicate pentru k indică faptul că un model reușește să claseze mai bine simplificările bune prezente în lista din set, cele slabe fiind mai jos în clasament.

Verificarea rezultatelor, luând în considerare formele de bază (lemele) ale cuvintelor, are scopul de a măsura corectitudinea generării de candidați de simplificare, fiind com-




Figura 4.5: Rezultatele pentru metrica Precision@k

parată cu lista întreagă de sugestii. O creștere substanțială indică faptul că un model reușește să identifice corect cuvintele pentru simplificare, dar face greșeli gramaticale, prezicând incorect forma lor. În schimb, o creștere mai mică arată că un model reușește să determine corect forma gramaticală bună a candidaților.

4.1.2 Rezultatele modelelor

Modelul de limbaj mascat cu performanța cea mai bună este *dumitrescustefan/bert-base-romanian-cased-v1* [5], fiind aproape mereu cel mai bine clasat. Are cel mai mare scor de acuratețe, reușind cel mai bine să claseze alternativa optimă printre primele sugestii. De asemenea, atât pentru acuratețe, cât și pentru potențial, are scoruri apropiate pentru parametrul k începând de la 3, indicând faptul că modelul reușește să clasifice în top simplificările din lista standard a propoziției. Precizia este foarte mare pentru k egal cu 1, dar scade semnificativ, deci modelul reușește să pună simplificările proaste la coada clasamentului. Dacă se iau în considerare lemele cuvintelor, scorul nu crește mult, însemnând că BERT-Romanian prezice cuvintele la forma gramaticală corectă.

GPT-4o mini [17] este al doilea cel mai performant model în general și LLM-ul mai bun pentru cerința de simplificare de text, în patru din cinci clasamente având al doilea cel mai bun scor de-a lungul graficelor. În general, evoluția scorurilor este asemănătoare cu cea a BERT-Romanian, dar cu valori puțin mai mici. Însă există câteva excepții, precum acuratețea, care are o creștere bruscă la schimbarea parametrului k de la 1 la 3, indicând faptul că, deși modelul nu reușește să identifice corect sugestia de top, tot se află în topul clasamentului, de obicei în primele trei predicții. Față de modelul anterior, are o creștere mai semnificativă la scorurile bazate pe leme, însemnând că are o performanță mai slabă și la identificarea formei gramaticale corecte a unui cuvânt.

Următorul model este reprezentat de RoLlama3 [14], și acesta fiind tot un Large Language Model. Deși a fost antrenat specific pentru limba română, a avut performanță mai proastă decât GPT-4o mini, care este multilingvistic. A reușit în schimb să aibă scor mai bun pe metrica MAP, fiind cel mai bine clasat model pentru parametrul k egal cu 5 care ar putea sugera că are o acuratețe mare. Dar, datorită metricii Recall mult mai slabe, această performanță ar putea fi cauzată de sugestii repetate ale aceluiași cuvânt, explicând și acoperirea proastă a cuvintelor din lista standard de alternative și posibila acuratețe mare în ciuda acesteia. De asemenea, acest lucru ar putea semnifica o slăbiciune mare a modelului, fiind incapabil să genereze cuvinte noi. Llama3ro are și o creștere bruscă la scorurile ce folosesc lemele cuvintelor, indicând faptul că modelul face multe greșeli gramaticale. Ambele slăbiciuni ar putea în schimb fi rezolvate cu un prompt mai bun, care, deși este echivalent cu cel folosit pentru GPT-4o mini, în acest caz, ar avea nevoie de instrucțiuni suplimentare legate de nerepetarea sugestiilor și generarea formei corecte a candidaților de simplificare.

RoBERT-Large [15] are o parte din scoruri apropiate de cele ale RoLlama3, dar puțin mai bune pentru parametrul k mic, mai ales pentru acuratețe, indicând faptul că are o performanță mai bună în alegerea candidatului de top. De asemenea, rezultatele sunt mult mai consistente și nu prezintă o creștere semnificativă la scorul pentru leme, deci evită slăbiciunile modelului RoLlama3. În schimb, deși este tot un model BERT [4] antrenat pe limba română ca BERT-Romanian [5], are o performanță mult mai slabă ca acesta.

Modelul de BERT-Romanian [5] antrenat are rezultate asemănătoare, dacă nu chiar mai bune în unele metrice decât RoBERT-Large. Reușește la generarea de candidați, având scoruri medii pentru Potential și Recall, dar este slab la alegerea candidatului de simplificare cel mai bun, având scoruri mai slabe decât modelul anterior pentru parametrul k egal cu 1. Cea mai probabilă cauză este neantrenarea suficientă a modelului, setul de date fiind mic, mai ales comparativ cu mărimea limbii române. În schimb, are acuratețe mai bună decât un model neantrenat, în Tabela B.1 având în general scoruri mai bune la rezultatele pe setul de testare decât modelul neantrenat pentru parametrul k egal cu 1 sau 3. Acest fapt înseamnă că, totuși, modelul antrenat tot a reușit să fie antrenat pe alegerea celui mai bun candidat de simplificare.

Cel mai prost clasat model este BERT-Multilingual [4], având, în general, cele mai slabe scoruri. Modelul pare să facă greșeli gramaticale în număr semnificativ, iar o posibilă explicație este că, deși este antrenat și pe limba română, nespecializarea lui și posibil neantrenarea suficientă îl provoacă să aibă performanțe slabe. Dar GPT-4o mini [17] a reușit să aibă scoruri bune, fiind și el disponibil pentru mai multe limbi.

4.2 Simplificare de Propoziții

S-au luat în considerare patru metrice calculate în urma rezultatelor de la adnotări. Scorul mediu indică performanța medie a unui model. Clasamentul mediu reprezintă un punct de comparație a unui model față de celelalte. Următoarele două metrice sunt asemănătoare, fiind bazate pe procentul de simplificări generate de un model cărora li s-a dat un scor peste o anumită valoare. Pentru simplificări excelente s-a luat în considerare

Model	Scor Mediu	Clasament Mediu	Simplificări (%)	
			Excelente	Acceptabile
BERT-Romanian	7.90	1.60	40.33%	62.39%
GPT-4o mini	7.65	1.90	36.77%	58.00%
RoLlama3	6.52	2.66	18.26%	32.62%
MILES	3.81	3.83	2.84%	5.81%

Tabela 4.1: Performanța Modelelor pe Simplificare de Propoziții pe setul de date Romanian Corpus [12]

Model	Scor Mediu	Clasament Mediu	Simplificări (%)	
			Bune	Acceptabile
BERT-Romanian	8.06	1.58	43.22%	66.14%
GPT-4o mini	7.91	1.92	37.5%	59.37%
RoLlama3	6.72	2.68	22.39%	39.06%
MILES	4.31	3.80	4.68%	11.45%

Tabela 4.2: Performanța Modelelor pe Simplificare de Propoziții pe setul de date de la MultipIYEYE [21, 22]

scorul 8, peste media celor mai bine performante modele, dar tot putând să aibă greșeli minore gramaticale, să nu simplifice în cel mai bun mod un cuvânt sau să se folosească înlocuiri care, deși sunt mai simple, nu sunt sinonime perfecte și se pierde din sensul original al propoziției. Pentru simplificări acceptabile s-a luat în considerare scorul 7, pentru care o propoziție poate avea o greșeală majoră, deși restul simplificării de propoziție este în regulă.

În general, modelele au performat mai bine pe setul de date de la MultipIYEYE [21, 22], deși scopul setului era ca unul în afara domeniului, pentru care nu au fost pregătite modelele. Un posibil motiv ar putea fi incluziunea în primul set de date a propozițiilor care nu necesitau în mod necesar simplificări, ducând la posibile greșeli sau complicități redundante asupra propoziției. Din toate categoriile de text, modelele au performat cel mai prost pe manuale școlare, posibila cauză fiind termenii specifici utilizați ce, deși sunt complecși, nu au alternative mai ușoare de înțeles, dar tot se încearcă simplificarea lor. Categoria cea mai bine performantă sunt știrile, datorită limbajului mai simplu și termenilor nespecifici unui domeniu utilizați, știrile fiind scrise pentru înțelesul întregului public.




Figura 4.6: Scor Mediu pentru fiecare Categorie




Figura 4.7: Clasament Mediu pentru fiecare Categorie

Modelul cu performanța cea mai bună este *dumitrescustefan/bert-base-romanian-cased-v1* [5], având cele mai bune scoruri în toate cele patru metrici, pe ambele seturi de date. Performanța sa pe setul de la MultipleEYE a avut o creștere minoră în toate metricile. Deși are clasamentul cel mai bun, acesta ar putea fi puțin favorizat datorită faptului că, la adnotare, acesta se afla ca prima opțiune, deci în cazuri de egalitate de scor pentru o simplificare, era mai probabil să fie clasat primul. Dar, din moment ce tot are cele mai bune rezultate pe celelalte trei metrici, acest fapt nu a influențat semnificativ performanțele față de celelalte modele, rămânând cel mai bun clasat.

Următorul model ca performanță este GPT-4o mini [17], având scoruri apropiate de modelul anterior. Pe setul de la MultipleEYE, are o creștere semnificativă în scorul mediu, deși procentul de simplificări bune și acceptabile nu are o schimbare majoră, indicând




Figura 4.8: Procent de Simplificări Excelente (cu scor >8) și Acceptabile (cu scor >7) pentru fiecare Categorie

faptul că modelul reușește să facă mai puține greșeli în simplificările slabe, cele mai bune rămânând la fel. Față de BERT-Romanian, GPT-4o mini poate fi considerat că a avut o performanță mai bună pe articole de cercetare, datorită scorului și clasamentului foarte apropiate și a procentului puțin mai bun de simplificări excelente și acceptabile. De asemenea poate fi considerat și mai bun pe categoria de știri datorită diferenței semnificative în numărul de simplificări excelente ale acestuia. Diferența cea mai mare apare la literatură tradusă, performând semnificativ mai slab decât modelul de top. Toate acestea arată că se descurcă mai bine la simplificarea termenilor specifici din diverse domenii de cercetare, dar și cei mai familiari, dar, paradoxal, are o performanță mai proastă cu termeni străini, care nu provin din limba română, deși modelul este antrenat specific să fie disponibil pentru mai multe limbi.

RoLlama3 [14] a avut consistent o performanță semnificativ mai slabă decât celelalte două modele. Ca și celelalte, prezintă o creștere în scorurile pentru setul de la MultiPLEYE. Categoria în care se apropie cel mai mult este literatură română, indicând că este mai bine antrenat pe cuvinte familiare ale limbii române, și nu cu termeni specifici unor domenii sau care provin din alte limbi. În ciuda performanțelor dezamăgitoare, modelul tot poate fi considerat acceptabil în mare parte din simplificări.

Cel mai slab performant model este MILES [11], fiind consistent cel mai prost clasat. Singurul plus ar fi că, față de celelalte modele, nu pare să aibă aceeași scădere în performanță în categoria textelor din manuale. În general face simplificări foarte slabe și este neutilizabil în practică.

4.3 Rezultate Totale

Modelul care a avut performanța cea mai bună pe ambele evaluări este *dumitrescusestefan/ bert-base-romanian-cased-v1* [5], fiind modelul BERT [4] antrenat specific pe limba română. Deși și RoBERT-Large [15] este același tip de model ca cel anterior, performanțele lui semnificativ mai slabe pe Simplificare Lexicală a făcut inutilă și verificarea lui pe Simplificare de Propoziții. Modelul GPT-4o mini [17] a avut rezultate apropiate de BERT-Romanian, dar de obicei cu scoruri puțin mai mici, la care se adaugă și dezavantajul legat de costul computațional mult mai ridicat, având nevoie de un gpu sau o mașină dedicată, pe când BERT-Romanian poate rula și pe mașini locale. RoLlama3 [14], deși este un LLM antrenat specific pentru limba română, a avut rezultate mai slabe, mai ales la generarea de simplificări pentru un cuvânt. În schimb, are rezultate mai bune în practică, la simplificarea de propoziții, fiind ajutat de algoritm pentru alegerea unui candidat potrivit și pentru corectarea unor greșeli gramaticale făcute. BERT-Multilingual [4], inclusiv atunci când este folosit în MILES [11], a avut rezultate foarte slabe.

Capitolul 5

Concluzii

În această lucrare am prezentat un framework și o modalitate de a face simplificare de text pentru limba română, luând în considerare și caracteristicile specifice, precum părțile de vorbire, genurile substantivelor, inflexiunile cuvintelor, și valorificând resursele valabile pentru aceasta.

Pe lângă algoritm, am evaluat și comparat diverse modele, folosite pentru generarea de predicții pentru limbaj mascat și pentru generarea de cuvinte candidat pentru simplificarea unui cuvânt anume. Am luat în considerare două tipuri de evaluare, cea a listei de candidați generată și clasarea lor de către modele și algoritm, și cea a simplificării de propoziții, alături de o evaluare umană a acestora.

Cel mai bine evaluat model a fost *dumitrescustefan/bert-base-romanian-cased-v1* [5], un model BERT antrenat pe limba română. El este cel mai bun model de utilizat în practică alături de algoritmul de simplificare implementat, nu numai pentru rezultatele bune ale acestuia, ci și pentru resursele computaționale puține care sunt necesare, putând să ruleze cu ușurință și pe mașini locale, chiar și pe un CPU, în loc de GPU dedicat. Un model bine evaluat este și GPT-4o mini [17], cu rezultate apropiate de cel anterior, dar cu costuri computaționale mult mai ridicate.

5.1 Lucrări viitoare

Pe viitor, ar putea fi extins și îmbunătățit algoritmul de simplificare prezentat în mai multe moduri. În primul rând, s-ar putea face o detectare mai bună a complexității cuvintelor, având un model antrenat specific pentru această sarcină în loc de folosirea frecvenței Zipf. De asemenea, pentru termeni complecși care nu au sinonime, s-ar putea adăuga definiții pentru aceștia în loc de simplificarea lor. O îmbunătățire în plus ar fi și detectarea de expresii și înlocuirea lor cu cuvinte sau alte expresii mai simple, deja cunoscute ca fiind echivalente în sens. O ultimă modificare ar fi schimbarea criteriilor luate în considerare la clasificarea candidaților de simplificare, prin adăugarea, înlocuirea sau modificarea unora.

Pe viitor se pot folosi și alte modele pentru predicțiile mascate folosite la generarea candidaților de simplificare. În special, cu apariția recentă a unui model cu mult îmbunătățit de BERT [4], și anume ModernBERT [26], se poate antrena acest model și pe limba română și folosi în locul modelului BERT-Romanian [5], care deja a avut rezultatele cele mai bune.

Scopul textelor din setul de date de la MultipleYE [21, 22] este urmărirea oculară a citirii unor cuvinte, cât de mult se oprește vederea pe anumiți termeni. Considerând acest scop, se pot folosi și propozițiile simplificate extrase din acest set la urmărirea oculară și să se compare timpul de citire inițial cu cel al cuvintelor simplificate și dacă simplificarea textului aduce îmbunătățiri la timpul de parcurgere și înțelegere a acestuia.

Bibliografie

- [1] URL: <https://www.dictionardesinonime.ro> (accesat în 4.6.2025).
- [2] URL: <https://www.dexonline.ro> (accesat în 4.6.2025).
- [3] Petru Cristea și Sergiu Nisioi, „Archaeology at MLSP 2024: Machine Translation for Lexical Complexity Prediction and Lexical Simplification”, în *Proceedings of the 19th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2024)*, ed. de Ekaterina Kochmar, Marie Bexthe, Jill Burstein, Andrea Horbach, Ronja Laarmann-Quante, Anaïs Tack, Victoria Yaneva și Zheng Yuan, Mexico City, Mexico: Association for Computational Linguistics, Iun. 2024, pp. 610–617, URL: <https://aclanthology.org/2024.bea-1.55/>.
- [4] Jacob Devlin, Ming-Wei Chang, Kenton Lee și Kristina Toutanova, „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, în *CoRR* abs/1810.04805 (2018), arXiv: [1810.04805](https://arxiv.org/abs/1810.04805).
- [5] Stefan Dumitrescu, Andrei-Marius Avram și Sampo Pyysalo, „The birth of Romanian BERT”, în *Findings of the Association for Computational Linguistics: EMNLP 2020*, Online: Association for Computational Linguistics, Nov. 2020, pp. 4324–4328, DOI: [10.18653/v1/2020.findings-emnlp.387](https://doi.org/10.18653/v1/2020.findings-emnlp.387).
- [6] Hugging Face, URL: <https://huggingface.co> (accesat în 5.6.2025).
- [7] Juri Ganitkevitch, Benjamin Van Durme și Chris Callison-Burch, „PPDB: The Paraphrase Database”, în *Proceedings of the 2013 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, ed. de Lucy Vanderwende, Hal Daumé III și Katrin Kirchhoff, Atlanta, Georgia: Association for Computational Linguistics, Iun. 2013, pp. 758–764, URL: <https://aclanthology.org/N13-1092/>.
- [8] Matthew Honnibal, Ines Montani, Sofie Van Landeghem și Adriane Boyd, *spaCy: Industrial-strength Natural Language Processing in Python*, 2020, DOI: [10.5281/zenodo.1212303](https://doi.org/10.5281/zenodo.1212303), URL: <https://spacy.io> (accesat în 29.5.2025).
- [9] HumanSignal, URL: <https://labelstud.io> (accesat în 13.6.2025).

- [10] Armand Joulin, Edouard Grave, Piotr Bojanowski, Matthijs Douze, H erve J egou  i Tomas Mikolov, „FastText.zip: Compressing text classification models”,  n *arXiv preprint arXiv:1612.03651* (2016), arXiv: [1612.03651](https://arxiv.org/abs/1612.03651), URL: <https://fasttext.cc> (accesat  n 22.5.2025).
- [11] Kvasirs, *MILES*, 2021, URL: <https://github.com/Kvasirs/MILES> (accesat  n 3.6.2025).
- [12] lmidriganciochina, *Romanian Corpus*, GitHub repository, 2020, URL: <https://github.com/lmidriganciochina/romaniancorpus> (accesat  n 6.6.2025).
- [13] Mounica Maddela, Yao Dou, David Heineman  i Wei Xu, „LENS: A Learnable Evaluation Metric for Text Simplification”,  n *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, ed. de Anna Rogers, Jordan Boyd-Graber  i Naoaki Okazaki, Toronto, Canada: Association for Computational Linguistics, Iul. 2023, pp. 16383–16408, DOI: [10.18653/v1/2023.acl-long.905](https://doi.org/10.18653/v1/2023.acl-long.905).
- [14] Mihai Masala, Denis C. Ilie-Ablachim, Alexandru Dima, Dragos Corlatescu, Miruna Zavelca, Ovio Olaru, Simina Terian-Dan, Andrei Terian-Dan, Marius Leordeanu, Horia Velicu, Marius Popescu, Mihai Dascalu  i Traian Rebedea, „*Vorbe ti Rom ne te?*” *A Recipe to Train Powerful Romanian LLMs with English Instructions*, 2024, arXiv: [2406.18266](https://arxiv.org/abs/2406.18266) [cs.CL].
- [15] Mihai Masala, Stefan Ruseti  i Mihai Dascalu, „RoBERT–A Romanian BERT Model”,  n *Proceedings of the 28th International Conference on Computational Linguistics*, 2020, pp. 6626–6637, DOI: [10.18653/v1/2020.coling-main.581](https://doi.org/10.18653/v1/2020.coling-main.581).
- [16] Kai North, Tharindu Ranasinghe, Matthew Shardlow  i Marcos Zampieri, *MultiLS: A Multi-task Lexical Simplification Framework*, 2024, arXiv: [2402.14972](https://arxiv.org/abs/2402.14972) [cs.CL].
- [17] OpenAI, *GPT-4o Mini: Advancing Cost-Efficient Intelligence*, 2024, URL: <https://openai.com/index/gpt-4o-mini-advancing-cost-efficient-intelligence/> (accesat  n 5.6.2025).
- [18] Gustavo Paetzold  i Lucia Specia, „Benchmarking Lexical Simplification Systems”,  n *Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC’16)*, ed. de Nicoletta Calzolari, Khalid Choukri, Thierry Declerck, Sara Goggi, Marko Grobelnik, Bente Maegaard, Joseph Mariani, Helene Mazo, Asuncion Moreno, Jan Odijk  i Stelios Piperidis, Portoro , Slovenia: European Language Resources Association (ELRA), Mai 2016, pp. 3074–3080, URL: <https://aclanthology.org/L16-1491/>.
- [19] Jipeng Qiang, Yun Li, Yi Zhu, Yunhao Yuan  i Xindong Wu, „LSBert: A Simple Framework for Lexical Simplification”,  n *CoRR* abs/2006.14939 (2020), arXiv: [2006.14939](https://arxiv.org/abs/2006.14939).

- [20] Railway, URL: <https://railway.com> (accesat în 7.6.2025).
- [21] COST (European Cooperation in Science și Technology), URL: <https://multipleye.eu> (accesat în 6.6.2025).
- [22] COST (European Cooperation in Science și Technology), URL: <https://multipleye.eu/wp-content/uploads/MultipleYE-Data-Collection-Guidelines.pdf#page=10> (accesat în 6.6.2025).
- [23] Matthew Shardlow, Fernando Alva-Manchego, Riza Batista-Navarro, Stefan Bott, Saul Calderon Ramirez, Rémi Cardon, Thomas François, Akio Hayakawa, Andrea Horbach, Anna Hülsing, Yusuke Ide, Joseph Marvin Imperial, Adam Nohejl, Kai North, Laura Occhipinti, Nelson Pérez Rojas, Nishat Raihan, Tharindu Ranasinghe, Martin Solis Salazar, Marcos Zampieri și Horacio Saggion, „An Extensible Massively Multilingual Lexical Simplification Pipeline Dataset using the MultiLS Framework”, în *Proceedings of the 3rd Workshop on Tools and Resources for People with READING Difficulties (READI) @ LREC-COLING 2024*, ed. de Rodrigo Wilkens, Rémi Cardon, Amalia Todirascu și Núria Gala, Torino, Italia: ELRA și ICCL, Mai 2024, pp. 38–46, URL: <https://aclanthology.org/2024.readi-1.4/>.
- [24] Matthew Shardlow, Fernando Alva-Manchego, Riza Batista-Navarro, Stefan Bott, Saul Calderon Ramirez, Rémi Cardon, Thomas François, Akio Hayakawa, Andrea Horbach, Anna Hülsing, Yusuke Ide, Joseph Marvin Imperial, Adam Nohejl, Kai North, Laura Occhipinti, Nelson Pérez Rojas, Nishat Raihan, Tharindu Ranasinghe, Martin Solis Salazar, Sanja Štajner, Marcos Zampieri și Horacio Saggion, „The BEA 2024 Shared Task on the Multilingual Lexical Simplification Pipeline”, în *Proceedings of the 19th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2024)*, ed. de Ekaterina Kochmar, Marie Bexte, Jill Burstein, Andrea Horbach, Ronja Laarmann-Quante, Anaïs Tack, Victoria Yaneva și Zheng Yuan, Mexico City, Mexico: Association for Computational Linguistics, Iun. 2024, pp. 571–589, URL: <https://aclanthology.org/2024.bea-1.51/>.
- [25] Robyn Speer, *rspeer/wordfreq: v3.0*, versiunea v3.0.2, Sept. 2022, DOI: [10.5281/zenodo.7199437](https://doi.org/10.5281/zenodo.7199437), URL: <https://pypi.org/project/wordfreq> (accesat în 22.5.2025).
- [26] Benjamin Warner, Antoine Chaffin, Benjamin Clavié, Orion Weller, Oskar Hallström, Said Taghadouini, Alexis Gallagher, Raja Biswas, Faisal Ladhak, Tom Aarsen, Nathan Cooper, Griffin Adams, Jeremy Howard și Iacopo Poli, *Smarter, Better, Faster, Longer: A Modern Bidirectional Encoder for Fast, Memory Efficient, and Long Context Finetuning and Inference*, 2024, arXiv: [2412.13663](https://arxiv.org/abs/2412.13663) [cs.CL].

Anexa A

Simplificare Lexicală

Model	k = 1	k = 3	k = 5	max k	lemma
BERT-Romanian	0.3793	0.5339	0.5878	0.6370	0.6627
RoBERT-large	0.1915	0.2453	0.2616	0.2710	0.3341
BERT-Multilingual	0.1002	0.1145	0.1169	0.1193	0.1885
Trained BERT-Romanian	0.1395	0.2635	0.3023	0.3643	0.3953
GPT-4o mini	0.1904	0.4333	0.4928	0.5333	0.6166
RoLlama3	0.1164	0.1903	0.2215	0.2897	0.5142

Tabela A.1: Rezultatele modelelor pentru Accuracy@k@top1. Se observă că cel mai bun model este BERT-Romanian, urmat de GPT-4o mini.

Model	k = 3	k = 4	k = 5
BERT-Romanian	0.3640	0.2949	0.2503
RoBERT-large	0.1512	0.1208	0.1017
BERT-Multilingual	0.0873	0.0685	0.0566
Trained BERT-Romanian	0.1632	0.1321	0.1100
GPT-4o mini	0.2896	0.2401	0.1984
RoLlama3	0.2970	0.2716	0.2538

Tabela A.2: Rezultatele modelelor pentru MAP@k. Se observă că cel mai bun model este BERT-Romanian, urmat de RoLlama3.

Model	k = 1	k = 3	k = 5	max k	lemma
BERT-Romanian	0.6651	0.7939	0.8126	0.8243	0.8571
RoBERT-large	0.2850	0.3574	0.3714	0.3925	0.4766
BERT-Multilingual	0.1599	0.1957	0.2100	0.2100	0.2935
trained BERT-Romanian	0.2713	0.4496	0.4883	0.5658	0.6046
GPT-4o-mini	0.3809	0.5928	0.6500	0.7142	0.8095
RoLlama3	0.2159	0.3210	0.3693	0.4545	0.7500

Tabela A.3: Rezultatele modelelor pentru Potential@k. Se observă că cel mai bun model este BERT-Romanian, urmat de GPT-4o mini.

Model	k = 1	k = 3	k = 5	max k	lemma
BERT-Romanian	0.1803	0.2996	0.3479	0.4031	0.4260
RoBERT-large	0.0773	0.1141	0.1261	0.1452	0.1807
BERT-Multilingual	0.0431	0.0573	0.0624	0.0643	0.0927
Trained BERT-Romanian	0.0738	0.1371	0.1624	0.2194	0.2447
GPT-4o mini	0.1032	0.2406	0.2922	0.3529	0.4070
RoLlama3	0.0588	0.1037	0.1269	0.1803	0.3150

Tabela A.4: Rezultatele modelelor pentru Recall@k. Se observă că cel mai bun model este BERT-Romanian, urmat de GPT-4o mini.

Model	k = 1	k = 3	k = 5	max k	lemma
BERT-Romanian	0.6651	0.3701	0.2591	0.1644	0.2476
RoBERT-large	0.2850	0.1422	0.0962	0.0653	0.1083
BERT-Multilingual	0.1599	0.0742	0.0515	0.0367	0.0672
Trained BERT-Romanian	0.2713	0.1679	0.1193	0.0806	0.1023
GPT-4o mini	0.3809	0.3107	0.2310	0.1499	0.1743
RoLlama3	0.2159	0.1998	0.1827	0.1423	0.2743

Tabela A.5: Rezultatele modelelor pentru Precision@k. Se observă că cel mai bun model este BERT-Romanian, urmat de GPT-4o mini.

Anexa B

Modelul BERT-Romanian Antrenat

Setul de date a fost împărțit în setul de antrenare și în setul de testare cu o rată de 0.3, însemnând că 30% din date au considerate ca date de testare. Modelul a fost antrenat cu următorii hiperparametrii:

- **Număr de epoci:** 5, dar rezultatul cel mai bun a fost cel de după prima epocă
- **Batch size:** 16
- **Rată de învățare:** 6×10^{-4}
- **Degradarea greutăților:** 0.001
- **Alpha:** 1

Metrică	Trained BERT-Romanian	Normal BERT-Romanian
Accuracy@1@top1	0.1395	0.1550
Accuracy@3@top1	0.2635	0.2403
Accuracy@5@top1	0.3023	0.3100
Accuracy@max@top1	0.3643	0.4496
Accuracy@lemma@top1	0.3953	0.4573
MAP@3	0.1632	0.1515
MAP@4	0.1321	0.1253
MAP@5	0.1100	0.1061
Recall@1	0.0738	0.0675
Recall@3	0.1371	0.1244
Recall@5	0.1624	0.1751
Recall@max	0.2194	0.2531
Recall@lemma	0.2447	0.2637
Potential@1	0.2713	0.2480
Potential@3	0.4496	0.3953
Potential@5	0.4883	0.5116
Potential@max	0.5658	0.6046
Potential@lemma	0.6046	0.6124
Precision@1	0.2713	0.2480
Precision@3	0.1679	0.1524
Precision@5	0.1193	0.1286
Precision@max	0.0806	0.0930
Precision@lemma	0.1023	0.1062

Tabela B.1: Comparație între modelul BERT antrenat și cel neantrenat pe setul de test, fără a folosi algoritmul de simplificare. Se observă faptul că modelul antrenat are scoruri mai bune pentru parametrii k egali cu 1 sau 3, deci are o îmbunătățire în alegerea celui mai bun candidat.

Anexa C

Simplificare de Propoziții

Set de Date	BERT-Romanian	GPT-4o mini	RoLlama3	MILES
Romanian Corpus	7.9098	7.6512	6.5255	3.8125
MultiplEYE	8.0625	7.9114	6.7239	4.3125
Articole de Cercetare	7.9154	7.8591	6.3239	2.5352
Filozofie	8.0357	7.9464	6.5357	4.3928
Istorie	8.1219	7.9634	6.6463	4.5121
Literatură Română	7.8786	7.7029	6.7196	3.7656
Literatură Tradusă	7.9191	7.3823	6.4816	3.6397
Manuale	7.2500	7.1093	5.9062	4.1718
Știri	8.2881	8.3050	6.6779	4.4237

Tabela C.1: Scorul Mediu al modelelor pe diverse seturi și subseturi de date. Se observă că cel mai bun model este BERT-Romanian, urmat de GPT-4o mini, care e chiar mai performant pe știri.

Set de Date	BERT-Romanian	GPT-4o mini	RoLlama3	MILES
Romanian Corpus	1.6049	1.9039	2.6607	3.8303
MultiplEYE	1.5885	1.9218	2.6875	3.8020
Articole de Cercetare	1.6197	1.7887	2.6056	3.9859
Filozofie	1.5892	1.8571	2.8035	3.7500
Istorie	1.5731	1.8780	2.8048	3.7439
Literatură Română	1.6401	1.8912	2.6234	3.8451
Literatură Tradusă	1.5514	2.0073	2.5735	3.8676
Manuale	1.7500	1.8125	2.7812	3.6562
Știri	1.5932	1.7966	2.8135	3.7966

Tabela C.2: Clasamentul Mediu al modelelor pe diverse seturi și subseturi de date. Se observă că cel mai bun model este BERT-Romanian, urmat de GPT-4o mini.

Set de Date	BERT-Romanian	GPT-4o mini	RoLlama3	MILES
Romanian Corpus	0.4033	0.3677	0.1826	0.0284
MultiplEYE	0.4322	0.3750	0.2239	0.0468
Articole de Cercetare	0.4366	0.4507	0.1126	0.0000
Filozofie	0.4821	0.4285	0.1785	0.0178
Istorie	0.4878	0.4024	0.1951	0.0487
Literatură Română	0.3765	0.3682	0.2008	0.0418
Literatură Tradusă	0.3970	0.3125	0.2058	0.0220
Manuale	0.2656	0.2500	0.0781	0.0312
Știri	0.4576	0.5423	0.1864	0.0169

Tabela C.3: Proporția de Simplificări Excelente a modelelor pe diverse seturi și subseturi de date. Se observă că cel mai bun model este BERT-Romanian, urmat de GPT-4o mini, care e chiar mai performant pe articole de cercetare și știri.

Set de Date	BERT-Romanian	GPT-4o mini	RoLlama3	MILES
Romanian Corpus	0.6239	0.5800	0.3262	0.0581
MultiplEYE	0.6614	0.5937	0.3906	0.1145
Articole de Cercetare	0.6478	0.6901	0.2112	0.0000
Filozofie	0.6071	0.5892	0.2678	0.0535
Istorie	0.7317	0.6707	0.3658	0.1097
Literatură Română	0.5815	0.5899	0.3765	0.0753
Literatură Tradusă	0.6360	0.5110	0.3382	0.0441
Manuale	0.4687	0.4687	0.1875	0.0312
Știri	0.7457	0.7118	0.3559	0.0847

Tabela C.4: Proporția de Simplificări Acceptabile a modelelor pe diverse seturi și subseturi de date. Se observă că cel mai bun model este BERT-Romanian, urmat de GPT-4o mini, care e chiar mai performant pe articole de cercetare, literatură română și la egalitate pe manuale.

C.1 Exemple de Simplificări

C.1.1 Exemple de Simplificări Foarte Bune

Original: Vom iniția un proces de stopare a construcțiilor ilegale admise de administrația municipală.

- **BERT-Romanian:** Vom iniția un proces de oprire a construcțiilor ilegale admise de administrația locală.
- **GPT-4o mini:** Vom începe un proces de oprire a lucrărilor ilegale aprobate de administrația publică.
- **RoLlama3:** Vom începe un proces de oprire a dezvoltărilor ilegale permise de administrația locală.

- **MILES:** Vom realiza un proces de continuare a materiale private create de administrația locale.

Original: Se ocupă de formalități atunci când intrăm în încăpere, dar refuză să discute în mod oficial cu noi și ne recomandă să găsim pe cineva mai curajos.

- **BERT-Romanian:** Se ocupă de proceduri atunci când intrăm în casă, dar refuză să discute în mod oficial cu noi și ne recomandă să găsim pe cineva mai curajos.
- **GPT-4o mini:** Se ocupă de proceduri atunci când venim în cameră, dar refuză să vorbească în mod oficial cu noi și ne sugerează să găsim pe cineva mai curajos.
- **RoLlama3:** Se ocupă de proceduri atunci când intră în cameră, dar refuză să vorbească în mod oficial cu noi și ne recomandă să găsim pe cineva mai curajos.
- **MILES:** Se ocupă de probleme atunci când eram în stare, dar decide să accepte în mod oficial cu noi și ne permite să găsim pe cineva mai bun.

Original: Totuși, în sânul echipei științifice s-a ajuns la o evidentă împărțire în două tabere antagonice.

- **BERT-Romanian:** Totuși, în interiorul echipei științifice s-a ajuns la o evidentă separare în două tabere opuse.
- **GPT-4o mini:** Totuși, în interiorul echipei științifice s-a ajuns la o clară împărțire în două tabere opuse.
- **RoLlama3:** Totuși, în interiorul echipei științifice s-a ajuns la o clară împărțire în două tabere.
- **MILES:** Totuși, în cadrul echipei științifice s-a ajuns la o singură autonomie în două zone diferite.

Original: Terenul trebuie izolat de clădirile din jur printr-un gard viu de tufari.

- **BERT-Romanian:** Terenul trebuie izolat de clădirile din jur printr-un gard viu de arbuști.
- **GPT-4o mini:** Terenul trebuie separat de casele din jur printr-un gard viu de flori.
- **RoLlama3:** Terenul trebuie izolat de casele din jur printr-un perete viu de copaci.
- **MILES:** Terenul trebuie separat de casă mari din jur printr-un drum viu de lemn.

C.1.2 Exemple de Simplificări Slabe

Câteva slăbiciuni ale algoritmului sunt țările, naționalitățile, monedele, animalele, părți ale corpului, elemente științifice, având tendința să încerce să le simplifice și, deși termenii modificați au o oarecare legătură, sensul textului devine cu totul altul. Mai jos sunt câteva exemple pentru aceste modificări slabe.

Original: Leul e mai jos ca leva bulgară și cursul mărcii s-a urcat cu diferența.

- **BERT-Romanian:** Leul e mai jos ca moneda română și cursul mărcii s-a urcat cu diferența.
- **GPT-4o mini:** Leu e mai jos ca euro bulgară și cursul coroana s-a urcat cu diferența.
- **RoLlama3:** Leul e mai jos ca euro bulgară și cursul leu s-a urcat cu diferența.
- **MILES:** Leul e mai jos ca cruce romana și cursul negre s - a luat cu respect.

Original: Vreo zece care trase de boi albi ca laptele, cu coarne mari.

- **BERT-Romanian:** Vreo zece care trase de oameni albi ca laptele, cu picioare mari.
- **GPT-4o mini:** Vreo zece care venite de cai albi ca laptele, cu aripi mari.
- **RoLlama3:** Vreo zece care trase de lapți albi ca laptele, cu coarne mari.
- **MILES:** Vreo zece care linii de cai negru ca copii, cu negre mari.

Original: A fost analizată componența atmosferei, care s-a dovedit a fi lipsită de oxigen; au fost efectuate măsurători deosebit de precise privind densitatea planetei, albedoul și alte elemente astronomice.

- **BERT-Romanian:** A fost analizată compoziția apei, care s-a dovedit a fi lipsită de oxigen; au fost efectuate studii deosebit de precise privind masa Pământului, temperatura și alte elemente astronomice.
- **GPT-4o mini:** A fost studiată compoziția aer, care s- a dovedit a fi lipsită de oxigen; au fost efectuate analize deosebit de exacte privind suprafața teren, temperatura și alte elemente astronomice.
- **RoLlama3:** A fost studiată elemente elemente, care s- a dovedit a fi compusă de oxigen; au fost efectuate observații deosebit de detaliate privind temperatura atmosferei, temperatura și alte elemente formare.
- **MILES:** A fost descoperit forma solare, care s - a dovedit a fi aproape de aer; au fost efectuate studii deosebit de simple privind temperatura acestuia, temperatura și alte elemente solare.

Original: Nu e de mirare ca te apaluda cerurile când te trezești.

- **BERT-Romanian:** Nu e de fapt ca te usu pământurile când te trezești.
- **GPT-4o mini:** Nu e de surpriză ca te apaluda stelele când te simți.
- **RoLlama3:** Nu e de surpriză ca te apaluda soare când te trezești.
- **MILES:** Nu e de fapt ca te ataca copii când te veni.

Original: Un nimb de măreție îți înconjoară tălpile goale.

- **MILES:** Un om de fotbal îți e gol gol.