

# Simplificare de Text pentru Limba Română

Absolvent: Anghel Fabian  
Coordonator științific: Nisioi Sergiu

Facultatea de Matematică și Informatică  
Universitatea din București

# Ce este Simplificarea de Text?

Rolul Simplificării de Text este de a înlocui anumite cuvinte sau fraze dintr-un text cu termeni familiari sau de a adăuga explicații la anumite noțiuni, toate cu scopul de a transforma un anumit text într-unul mai ușor de înțeles.

## Exemple de utilizări a Simplificării de Text

- învățarea limbii de către vorbitori străini
- creșterea clarității și simplității unui text pentru persoane cu dizabilități
- redactarea de texte pe înțelesul copiilor

# Simplificarea de Text pentru Limba Română

În acest moment, există puține modalități de a face simplificare de text în limba română. De asemenea, nu sunt disponibile unelte sau seturi de date suficient de mari pentru a antrena un model de la zero pe simplificare de text.

Având LSBert (un framework pentru simplificare de text în limba engleză) ca principala inspirație, am implementat un algoritm care se folosește de modele preantrenate pentru a simplifica anumite cuvinte dintr-o propoziție. În plus, am avut și alte contribuții, precum extragerea de date, atât pentru algoritm, cât și pentru seturile de evaluare, implementarea unei interfețe pentru adnotarea de simplificări și adnotarea datelor, antrenarea unui model BERT pentru simplificare de text și, în final, colectarea evaluărilor și calcularea rezultatelor.

# Algoritmul de simplificare

La simplificarea unei propoziții, se parcurg următorii pași:

1. Identificarea de cuvinte complexe
2. Generarea de simplificări utilizând un model preantrenat
3. Clasarea simplificărilor unui cuvânt după următoarele criterii:
  - frecvența utilizării cuvântului în limbaj
  - scorul returnat de modelul preantrenat
  - similaritatea dintre cuvântul original și simplificare
  - scorul de sinonimie
4. Înlocuirea cuvântului original cu cea mai bună simplificare, potențial corectând greșelile făcute

# Determinarea celui mai bun model preantrenat pentru simplificare

Algoritmul poate fi utilizat cu mai multe modele preantrenate care să genereze simplificări pentru un cuvânt. Scopul principal al metodelor de evaluare a fost să se determine care este cel mai potrivit model pentru simplificări în limba română.

## Moduri de evaluare

### 1. Simplificare Lexicală

- compararea simplificărilor unui cuvânt dintr-o propoziție cu un standard adnotat
- evaluarea generării și ordonării simplificărilor de către modele

### 2. Simplificare de Propoziții

- clasarea simplificărilor generate de mai multe modele ale aceleiași propoziții și punctarea lor între 1 și 10, totul de către evaluatori umani
- evaluarea modelelor pe diverse categorii de text

# Modele evaluate

## Modele BERT evaluate


- modele preantrenate
  - specific pentru limba română (BERT-Romanian, RoBERT-Large)
  - pentru mai multe limbi (BERT-Multilingual)
- model BERT-Romanian antrenat de mine pe o parte din setul de date al Simplificării Lexicale, evaluat pe restul setului

## LLM-uri evaluate

- modele preantrenate
  - pentru mai multe limbi (GPT-4o mini)
  - pentru limba română (RoLlama3)

# Rezultate pentru Simplificare Lexicală

- Modelul cu performanțele cele mai bune în majoritatea metricilor este BERT-Romanian, urmat de GPT-4o mini, cu scoruri apropiate.
- RoBERT-Large, are rezultate semnificativ mai slabe decât BERT-Romanian, ambele fiind preantrenate pentru română.
- Modelul antrenat, deși a avut un set de date restrâns pentru învățare, a reușit să aibă rezultate totale mai bune decât RoBERT-Large, dar mai slabe în alegerea celui mai bun candidat.
- RoLlama3 pare să facă multe greșeli, datorită creșterii substanțiale a scorului când se verifică doar formele de bază a cuvintelor.
- BERT-Multilingual are cele mai slabe rezultate.



**Figure:** Acuratețea modelelor în a alege cea mai bună simplificare, pe un set de date format din 460 de grupuri de propoziții, cuvinte și liste de posibile simplificări, ordonate de un adnotator uman.

# Rezultate pentru Simplificare de Propoziții

- Din nou, modelul cel mai bun este BERT-Romanian, cu GPT-4o mini având scoruri apropiate.
- RoLlama3 are performanțe mai bune în această evaluare, fiind ajutat de ultimul pas al algoritmului implementat pentru corecturi la simplificări
- MILES, implementare a LSBert ce utilizează BERT-Multilingual, are rezultate foarte slabe, făcându-l neutilizabil pentru simplificări.

| Model         | Scor Mediu | Simplificări (%) |             |
|---------------|------------|------------------|-------------|
|               |            | Excelente        | Acceptabile |
| BERT-Romanian | 7.90       | 40.33%           | 62.39%      |
| GPT-4o mini   | 7.65       | 36.77%           | 58.00%      |
| RoLlama3      | 6.52       | 18.26%           | 32.62%      |
| MILES         | 3.81       | 2.84%            | 5.81%       |

**Table:** Performanțele generale ale modelelor pe un set de 460 de propoziții extrase din texte din Romanian Corpus, adnotate de 4 evaluatori.



# Rezultate pentru Simplificare de Propoziții

- GPT-4o mini pare să aibă rezultate mai bune pe două categorii de texte: Articole de Cercetare și Știri, dar semnificativ mai slabe în comparație cu alte categorii pe Literatură Tradusă.
- Cea mai slabă categorie de text pentru simplificări sunt Manualele Școlare.




Figure: Procentul de propoziții simplificate cu scorul dat mai mare decât 8, respectiv 7, pe diverse categorii de texte din același set de date, grupate după originea lor

Am introdus un algoritm care se folosește de modele preantrenate pentru predicție de text pentru a simplifica texte în limba română. Modelul cel mai performant, atât ca rezultate, cât și ca eficiență computațională, este BERT-Romanian.

Pe viitor, această implementare se poate extinde, și, în plus, să fie folosită cu modele ce vor apărea pe viitor, de exemplu în cazul în care se antrenează modelul ModernBERT pentru limba română.

**The End**